



UNIVERSIDAD DE CONCEPCIÓN
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS

Predicción de Fibrilación Auricular Paroxística Inminente mediante Máquinas de Vectores de Soporte

Por: Maximiliano Concha

Tesis presentada a la Facultad de Ciencias Físicas Y Matemáticas de la
Universidad de Concepción

Noviembre 2025
Concepción, Chile

Profesor Guía: Patricio Sáez
Colaboradores: Guillermo Ferreira, Patricio Salas

AGRADECIMIENTOS

A todo aquel que me ha hecho ser quien soy, en especial a mi familia que me apoyó en cada momento con su cariño, a mis amigos por su compañía y a todos los profesores que me enseñaron el camino a seguir.

Resumen

La fibrilación auricular es la arritmia cardíaca más común y constituye un importante desafío clínico debido a su asociación con eventos adversos como accidente cerebrovascular e insuficiencia cardíaca. La predicción temprana de la fibrilación auricular paroxística (PAF) permite la implementación de medidas preventivas que reducen riesgos y mejoran la calidad de vida de los pacientes. En este trabajo se propone un modelo predictivo basado en Máquinas de Vectores de Soporte (SVM), entrenado y evaluado sobre la base de datos del PhysioNet/Computing in Cardiology Challenge 2001. La metodología incluyó preprocesamiento de señales de electrocardiograma, segmentación en ventanas de 5 minutos, detección y delineación de ondas, y extracción de características tanto de variabilidad de la frecuencia cardíaca (VFC) como morfológicas de la onda P. Posteriormente, se optimizaron los hiperparámetros del modelo mediante GridSearchCV y validación cruzada. El sistema alcanzó una puntuación de 21/28 (75 %) en el Evento 2 del desafío: predicción de PAF, superando a los ganadores oficiales de 2001 (20/28), lo que evidencia la pertinencia de aplicar técnicas modernas de machine learning en este problema. Los resultados confirman la utilidad de la VFC y la morfología de la onda P como predictores de episodios inminentes de PAF, y posicionan a este enfoque como una alternativa robusta y competitiva. Finalmente, se concluye que este estudio valida la eficacia de los métodos clásicos de aprendizaje automático y sienta las bases para futuras investigaciones con arquitecturas más complejas como redes profundas.

Keywords – Fibrilación Auricular, Electrocardiograma, Máquinas de Vectores de Soporte, Predicción, Aprendizaje Automático.

Índice general

AGRADECIMIENTOS	I
Resumen	II
1. Introducción	1
1.1. Organización del Documento	3
2. Marco Teórico	4
2.1. El Electrocardiograma (ECG): Fundamentos y Funcionamiento	4
2.2. Componentes Morfológicos del ECG	5
2.2.1. Onda P	6
2.2.2. Complejo QRS	6
2.2.3. Onda T	6
2.2.4. Intervalos y Segmentos del ECG	6
2.3. Fibrilación Auricular: Definición, Tipos y Consecuencias	7
2.4. El Impacto Clínico de la Predicción Temprana de la Fibrilación Auricular Paroxística	9
2.5. Modelos Utilizados en la Predicción de Fibrilación Auricular Paroxística	10
2.6. El PhysioNet/Computing in Cardiology Challenge 2001	13
2.7. Novedad de la Propuesta	14
3. Objetivos y Actividades	16
3.1. Objetivo General	16
3.2. Objetivos Específicos	16
4. Metodología	17
4.1. Descripción de la base de datos	17
4.1.1. Preprocesamiento y segmentación en ventanas	20
4.1.2. Detección de Peaks R y Delineación de Ondas	22
4.1.3. Cálculo de Características	27
4.1.4. Selección de Características	31
4.1.5. Máquinas de Vectores de Soporte (SVM)	32
4.1.6. Optimización de Hiperparámetros: GridSearchCV, Optuna e Hyperopt	37
4.1.7. Generación de Predicciones para el Desafío	40

5. Resultados	41
5.1. Resultados Obtenidos	41
6. Discusión	44
Referencias	46

Índice de cuadros

4.1.1.Ejemplo comparativo de vectores de características HRV (ventana 1) para varios registros del grupo p. Cada fila representa una métrica extraída del ECG en una ventana de 5 minutos.	30
4.1.2.Comparación de métodos de optimización de hiperparámetros con 30 semillas. Se reporta la precisión del Grupo A (promedio $\pm$ desviación estándar) en el Evento 2.	37
5.1.1.Comparativa de resultados para el Evento 2 del PhysioNet Challenge 2001.	42

Índice de figuras

2.2.1.Ritmo sinusal normal	5
4.1.1. Guía de trabajo.	19
4.1.2.Comparación de la señal ECG a 128 Hz y 64 Hz.	20
4.1.3.Segmentación temporal de la señal ECG mediante ventanas de 5 minutos con solapamiento del 50 %, generando 11 ventanas por registro de 30 minutos. El desplazamiento vertical se utiliza únicamente con fines ilustrativos.	21
4.1.4.Ejemplo Detección de Peaks R y Delineación de Ondas con Neurokit2	25
4.1.5.Descomposicion del ECG p08 utilizando DWT	26
4.1.6.Gráfico comparativo de una característica entre los dos grupos	31
4.1.7.Transformación no lineal mediante el truco del kernel en una SVM	35

Capítulo 1

Introducción

El electrocardiograma (ECG), es crucial en el campo de la cardiología, ya que permite observar de forma clara la actividad eléctrica del corazón. A través de electrodos ubicados en la piel, se crea un gráfico que muestra los impulsos eléctricos que causan la contracción y relajación del corazón. Su asequibilidad, facilidad de acceso y gran efectividad para hacer diagnósticos han hecho que el ECG se convierta en una herramienta fundamental en la medicina moderna, siendo ampliamente utilizado para reconocer diferentes trastornos cardíacos.

Dentro de las enfermedades cardiovasculares, la fibrilación auricular (FA) es la arritmia más común y tiene un efecto considerable en la salud ([Fatih Gündüz and Fatih Talu, 2023](#)). Se define por un ritmo cardíaco irregular y, a menudo, acelerado que interfiere con la coordinación de las aurículas. Hay diferentes tipos de FA, como la paroxística, que se presenta de manera ocasional y puede transformarse en formas más duraderas o permanentes. La FA, en cualquiera de sus formas, está asociada con un mayor riesgo de sufrir un derrame cerebral, insuficiencia cardíaca o incluso la muerte, lo que la convierte en un importante desafío para la salud pública.

Uno de los mayores desafíos en la atención médica es identificar la PAF a tiempo y anticipar cuándo podría ocurrir un episodio. Esto sigue siendo un reto, incluso con las innovaciones tecnológicas actuales. Los métodos de diagnóstico tradicionales, como el ECG de 12 derivaciones, el monitoreo Holter (dispositivo que registra la actividad eléctrica del corazón durante 24 a 48 horas) y los dispositivos implantables de registro continuo, constituyen las principales herramientas clínicas para su detección; sin embargo, presentan limitaciones para identificar episodios breves o asintomáticos

de PAF [Camm AJ et al. \(2010\)](#). En particular, la detección definitiva requiere el registro de una arritmia con las características electrocardiográficas típicas de FA durante al menos 30 segundos en un trazado o un ECG de 12 derivaciones, lo que puede dificultar el diagnóstico en pacientes con episodios esporádicos. Esta limitación complica la implementación de medidas preventivas y reduce la capacidad de los médicos para reaccionar rápidamente, aumentando el riesgo de serias complicaciones para los pacientes.

En este contexto, los avances en estadística y aprendizaje automático abren nuevas oportunidades para enfrentar este desafío. Ya se han desarrollado diversos trabajos que aplican algoritmos de clasificación sobre señales de ECG para reconocer patrones que suelen pasar inadvertidos en el análisis clínico convencional. Por ejemplo, [Mohebbi and Ghassemian \(2012\)](#) utilizaron SVM para predecir episodios de PAF a partir de la variabilidad de la frecuencia cardíaca, mientras que [Ebrahimzadeh et al. \(2018\)](#) combinaron métricas de HRV y morfología auricular para entrenar clasificadores basados en mezcla de expertos y SVM. Más recientemente, estudios híbridos como el de [Nguyen et al. \(2021\)](#) integraron redes convolucionales (CNN) con clasificadores SVM para mejorar la detección de FA en registros de un solo canal.

La principal contribución de esta investigación es la creación y evaluación de un sistema predictivo basado en SVM, utilizando datos del Desafío PhysioNet/Computing in Cardiology 2001. El objetivo del estudio es mostrar cómo las técnicas modernas de procesamiento de señales y aprendizaje automático pueden facilitar la detección temprana de la PAF, brindando evidencia sobre la eficacia de estas herramientas para abordar un desafío clínico que ha sido difícil de solucionar durante mucho tiempo.

Esta investigación se encuentra dentro de esa línea de trabajos, pero con un enfoque aplicado y autónomo: se desarrolla un pipeline propio de preprocesamiento, segmentación, extracción de características y clasificación mediante SVM, entrenado sobre la base PhysioNet/Computing in Cardiology Challenge 2001. El trabajo busca demostrar la aplicabilidad práctica de las SVM para la predicción de episodios inminentes de PAF, reafirmando la vigencia de los métodos clásicos de aprendizaje automático en el análisis de señales biomédicas.

1.1. Organización del Documento

Este documento se organiza en varias secciones: el **Marco Teórico** se adentra en los conceptos del ECG, la definición de Fibrilación Auricular y la importancia clínica de anticipar Fibrilación Auricular Paroxística; la **Metodología** detalla el enfoque adoptado, describe los datos utilizados, el procedimiento seguido y el contexto del desafío empleado para la evaluación; el **Análisis** presenta y discute los resultados obtenidos, incluyendo una revisión de los progresos en el área; la **Discusión** considera las implicaciones y las perspectivas futuras de la investigación; y por último, la **Conclusión** sintetiza los hallazgos más importantes y sugiere direcciones para investigaciones futuras.

Capítulo 2

Marco Teórico

Esta parte establece los fundamentos teóricos de la investigación actual, iniciando con un análisis minucioso de la literatura relacionada con el electrocardiograma, su operativa y su desarrollo a lo largo de la historia, para posteriormente examinar la importancia clínica de la FA y la anticipación temprana de su manifestación paroxística.

2.1. El Electrocardiograma (ECG): Fundamentos y Funcionamiento

El electrocardiograma constituye una herramienta diagnóstica esencial en cardiología, ya que permite representar gráficamente la actividad bioeléctrica del corazón. Para interpretar correctamente estas señales, es necesario comprender tanto los principios eléctricos que las originan como el sistema de derivaciones que posibilita su registro.

El registro electrocardiográfico se obtiene mediante electrodos colocados en la superficie corporal, que actúan como sensores de voltaje. El electrocardiógrafo, en esencia, funciona como un voltímetro capaz de captar las diferencias de potencial generadas por la actividad eléctrica del miocardio. Estas variaciones se representan en forma de ondas, cuya polaridad y amplitud dependen de la dirección del impulso eléctrico respecto a los polos de la derivación [Hampton and Hampton \(2025\)](#).

La actividad eléctrica cardíaca se inicia en el sistema de conducción y se propaga a través del miocardio, desencadenando la contracción. La orientación del vector

eléctrico en relación con los electrodos determina si la onda es positiva o negativa, y distintas derivaciones ofrecen perspectivas complementarias de este mismo fenómeno. Gracias a ello, el ECG proporciona una visión tridimensional de la función cardíaca, facilitando la detección de alteraciones en la conducción o en la estructura del corazón.

2.2. Componentes Morfológicos del ECG

Un ciclo cardíaco normal en el trazado del ECG se compone de una serie de ondas distintivas: la onda **P**, el complejo **QRS** y la onda **T**. Cada una de estas ondas representa un evento eléctrico específico en el corazón y posee un significado clínico particular. Las definiciones se basan en [De Luna et al. \(2006\)](#).




Figura 2.2.1: Ritmo sinusal normal

2.2.1. Onda P

La onda P representa la despolarización auricular, es decir, la actividad eléctrica que provoca la contracción de las aurículas. Según Bayés de Luna et al., su amplitud no debe superar los 2,5mm y su duración no debe ser mayor a 0,1s. La onda P es típicamente redondeada y positiva.

2.2.2. Complejo QRS

El complejo QRS representa la **despolarización de los ventrículos** y está formado por tres componentes:

- **Onda Q:** Primera deflexión negativa no precedida por una R. La onda q fisiológica debe ser estrecha (0,04s) y de baja amplitud. Si la deflexión inicial es más ancha o profunda, se denomina onda Q.
- **Onda R:** Es la primera onda positiva y la más grande, reflejando la despolarización de la masa principal de los ventrículos.
- **Onda S:** Es la primera onda negativa después de la onda R, que representa la despolarización final de los ventrículos en la base del corazón.

La duración normal del QRS no debe superar 0,095–0,11s. Un complejo más ancho indica despolarización ventricular anormal.

2.2.3. Onda T

La onda T representa la **repolarización de los ventrículos**. Aunque la repolarización auricular también ocurre, suele quedar enmascarada por el complejo QRS.

2.2.4. Intervalos y Segmentos del ECG

Además de las ondas, el ECG presenta intervalos y segmentos que proporcionan información temporal crucial sobre la conducción eléctrica y la repolarización cardíaca.

Intervalo PR

El intervalo PR se mide desde el inicio de la onda P hasta el inicio del complejo QRS. Refleja el tiempo de conducción auriculoventricular, incluyendo la despolarización

auricular y la pausa en el nodo auriculoventricular (AV). Su duración normal oscila entre 0.12 y 0.20 segundos.

Intervalo QT y QTc

El intervalo QT se extiende desde el inicio del complejo QRS hasta el final de la onda T, representando la duración total de la despolarización y repolarización ventricular. Su duración depende de la frecuencia cardíaca, por lo que se emplea el intervalo QT corregido (QTc) para obtener una evaluación más precisa.

Segmento ST

Este segmento conecta el complejo QRS con la onda T y representa el periodo de repolarización ventricular completa. En condiciones normales, el segmento ST es isoelectrico o puede estar ligeramente por debajo de la línea basal.

Importancia Clínica y Aplicación en Aprendizaje Automático

Estos intervalos y segmentos proporcionan información temporal vital sobre la función cardíaca. Las desviaciones de sus valores normales son indicadores directos de patologías específicas [Krstacic et al. \(2001\)](#).

Dado que estos parámetros varían con la frecuencia cardíaca, su análisis debe considerar esta variabilidad. En el contexto del aprendizaje automático, estas características temporales complementan la información morfológica del ECG, ofreciendo una visión integral del funcionamiento cardíaco. Por ello, deben ser incorporadas sistemáticamente en cualquier proceso de extracción de características para tareas de clasificación o predicción clínica.

2.3. Fibrilación Auricular: Definición, Tipos y Consecuencias

La FA es una de las arritmias más frecuentes y se caracteriza por un latido cardíaco irregular y, a menudo, rápido. En la FA, las dos cámaras superiores del corazón (las aurículas) laten de forma caótica e irregular, en lugar de contraerse de manera coordinada. Esto provoca que la sangre no se bombee de manera eficiente al resto del cuerpo.

Clasificación Clínica de la FA

La FA se clasifica clínicamente según su presentación, duración y si los episodios terminan por sí solos:

- **FA de primer diagnóstico:** Es la primera vez que se detecta la FA en un paciente.
- **FA paroxística:** Episodios que aparecen y desaparecen por sí solos, generalmente en menos de 7 días.
- **FA persistente:** Es continua y dura más de 7 días, requiriendo intervención para restaurar el ritmo normal.
- **FA persistente de larga duración:** Es continua y dura más de 12 meses.
- **FA permanente:** Es continua y se acepta como el ritmo cardíaco del paciente, sin intentos de restaurar el ritmo normal.

Con el tiempo, la FA tiende a progresar naturalmente de la forma paroxística a la persistente o permanente.

Consecuencias Clínicas de la FA

Las consecuencias de la FA pueden ser graves y afectar significativamente la salud del paciente [Joglar et al. \(2024\)](#):

- **Accidente cerebrovascular (ACV) y embolia sistémica:** La FA aumenta considerablemente el riesgo de ACV y embolia sistémica debido a la formación de coágulos en las aurículas.
- **Insuficiencia cardíaca:** La FA puede contribuir al desarrollo o empeoramiento de la insuficiencia cardíaca y aumentar el riesgo de hospitalizaciones recurrentes.
- **Mortalidad:** La progresión de la FA se asocia con un incremento en la mortalidad por todas las causas.
- **Remodelación auricular:** La FA induce cambios estructurales y electrofisiológicos en las aurículas, como alteraciones en las corrientes iónicas y desarrollo de fibrosis, facilitando la persistencia de la arritmia.
- **Síntomas:** Aunque puede ser asintomática, la FA también puede manifestarse

con palpitaciones, mareos, aturdimiento, dificultad para respirar, debilidad, fatiga y reducción de la capacidad para realizar ejercicio.

La identificación temprana del tipo de FA (paroxística o persistente) es clave para su manejo escalonado. Sin embargo, las guías clínicas reconocen que muchas veces es difícil distinguirlas con precisión [Joglar et al. \(2024\)](#).

2.4. El Impacto Clínico de la Predicción Temprana de la Fibrilación Auricular Paroxística

La PAF, que aparece y desaparece, es un gran desafío en cardiología, por lo que predecir su inicio de forma precisa y temprana es de vital importancia. El avance de la FA está claramente relacionado con problemas cardiovasculares graves, incluido un mayor riesgo de derrame cerebral, coágulos en el cuerpo y hospitalización por insuficiencia cardíaca. Estas complicaciones resaltan la necesidad urgente de actuar a tiempo.

Identificar y tratar la FA a tiempo es esencial para mejorar los resultados del tratamiento, prolongar la vida del paciente y disminuir significativamente la probabilidad de complicaciones graves que a menudo ocurren debido a un diagnóstico y tratamiento tardíos. Por ejemplo, la detección anticipada de enfermedades, como el cáncer en sus fases iniciales, ha mostrado un aumento considerable en las tasas de supervivencia. Los estudios de seguimiento a largo plazo confirman esta necesidad, revelando una tasa de mortalidad general del 30.3 % a diez años después del primer diagnóstico de PAF en un individuo [Gunawardene and Willems \(2022\)](#). La llegada de tratamientos como las estrategias de control del ritmo en etapas tempranas y la ablación con catéter, refuerza fuertemente la necesidad de un tratamiento precoz. Estos enfoques han demostrado ser eficaces para mantener el ritmo cardíaco normal y ralentizar considerablemente el desarrollo de la FA, además de que la ablación con catéter disminuye significativamente la posibilidad de que la FA regrese.

Predecir la PAF es un paso esencial en la cardiología preventiva que va más allá de solo diagnosticar. Al predecir el inicio de la PAF, los médicos pueden aplicar estrategias para reducir riesgos, como el control temprano del ritmo o la ablación con catéter, que han demostrado ser efectivas para mantener el ritmo cardíaco normal y reducir problemas graves como el derrame cerebral y la insuficiencia cardíaca. Este enfoque

cambia la práctica médica de un tratamiento que reacciona a los problemas a uno que los previene activamente, lo que encaja con la medicina moderna personalizada y preventiva.

A pesar de esta profunda necesidad clínica, en 2001, no existían métodos ampliamente fiables o validados independientemente para predecir el inicio de la PAF. Incluso hoy en día, los médicos tienen dificultades para diferenciar bien entre los tipos de FA que aparecen y desaparecen (paroxística) y los que son constantes (persistente), lo que muestra una falta de herramientas de predicción que necesitan mejoras. El Desafío PhysioNet de 2001 fue una respuesta directa a esta necesidad clínica insatisfecha. Al revisar este problema antiguo con métodos modernos, este trabajo muestra el progreso real en el procesamiento de señales biomédicas y cómo puede ayudar a resolver desafíos médicos de hace mucho tiempo.

2.5. Modelos Utilizados en la Predicción de Fibrilación Auricular Paroxística

El estudio de la predicción de PAF ha evolucionado en paralelo con el desarrollo de técnicas de procesamiento de señales y algoritmos de clasificación. Su trayectoria puede dividirse en cuatro etapas principales: métodos clásicos, el problema PhysioNet Challenge 2001, los enfoques de aprendizaje automático y los más recientes modelos de aprendizaje profundo.

Los primeros intentos de predicción se centraron en el análisis de la variabilidad de la frecuencia cardíaca (HRV), derivada de los intervalos RR del ECG. Las métricas en el dominio temporal (media, desviación estándar, RMSSD, pNN50), frecuencial (bandas baja frecuencia (LF) y alta frecuencia(HF)) y no lineal (entropía aproximada, dimensión fractal) se utilizaron para describir la modulación autonómica cardíaca [Costin et al. \(2013\)](#).

A medida que avanzó la investigación, se incorporaron herramientas de análisis tiempo-frecuencia, como la Transformada Wavelet, capaces de detectar irregularidades transitorias en la señal cardíaca y aportar sensibilidad en la detección temprana de episodios arrítmicos [Thuraisingham \(2007\)](#).

Estos métodos ofrecieron información fisiológicamente relevante, pero su desempeño predictivo en la práctica clínica era limitado debido a la dependencia de condiciones

experimentales controladas y la variabilidad entre pacientes.

Profundizando en esta línea, la investigación exploró características más avanzadas derivadas de la HRV. Por ejemplo, [Mohebbi and Ghassemian \(2012\)](#) no solo utilizaron métricas no lineales, sino que introdujeron el análisis del bispectro de la señal de intervalos RR. Esta técnica permitió detectar interacciones no lineales, revelando dinámicas sutiles del sistema nervioso autónomo que el espectro de potencia convencional (LF/HF) no puede capturar. En un enfoque complementario, que se desvía del análisis exclusivo de la variabilidad del ritmo, [Thong et al. \(2004\)](#) demostraron que la cuantificación de Complejos Auriculares Prematuros (CAPs) era un potente predictor. Su trabajo estableció que no solo la variabilidad del ritmo, sino la presencia y frecuencia de estos ectópicos auriculares (latidos irregulares), conocidos por ser disparadores de la arritmia, contenían información predictiva crucial.

[Sáez and Herrera \(2015\)](#) propusieron un método basado en Cadenas de Markov para modelar la secuencia de intervalos RR. En lugar de tratar los intervalos como una colección de datos, su enfoque identifica estados a partir de dos series de tiempo correspondientes a los intervalos RR y PR (por ejemplo, ritmo corto, medio, largo). El núcleo del método reside en analizar la matriz de transición entre estos estados, la cual captura la probabilidad de que un tipo de latido sea seguido por otro. La hipótesis es que un estado pre-fibrilatorio se caracteriza por una alteración en la predictibilidad y estructura de estas transiciones. Por tanto, las características extraídas de esta matriz de probabilidad, sirven como un poderoso predictor de la inestabilidad arrítmica inminente.

El paso natural desde el análisis de características aisladas hacia modelos integradores fue demostrado por trabajos como el de [Narin et al. \(2018\)](#), quienes se enfocaron en la predicción temprana utilizando segmentos de HRV a corto plazo. Su enfoque consistió en extraer un conjunto de características de HRV de segmentos de solo 5 minutos y utilizarlas para entrenar una red neuronal artificial como clasificador. Este tipo de estudios fue fundamental, pues validó que la combinación de múltiples descriptores fisiológicos, incluso de grabaciones breves, con algoritmos de clasificación, podía superar las limitaciones de los umbrales de métricas individuales y sentó las bases para la adopción de modelos de aprendizaje automático más complejos.

Posteriormente, con el auge del aprendizaje automático, se introdujeron algoritmos capaces de integrar múltiples características heterogéneas y ofrecer mayor robustez

frente a la variabilidad de los datos. Entre los más utilizados se encuentran árboles de decisión, Random Forest, k-NN y, de forma destacada, las Máquinas de Vectores de Soporte (SVM).

Las Máquinas de Vectores de Soporte (SVM) son clasificadores supervisados que buscan el hiperplano que maximiza el margen entre dos clases, garantizando una mayor capacidad de generalización [Cristianini and Scholkopf \(2002\)](#). A través del uso de funciones kernel (lineal, polinomial, radial RBF), permiten modelar fronteras de decisión no lineales en espacios de alta dimensionalidad.

En el análisis de ECG, las SVM ofrecen ventajas concretas:

- Integran eficazmente características de distinta naturaleza, como HRV y morfología de ondas.
- Requieren un número de muestras moderado, siendo adecuadas para bases como PhysioNet 2001.
- Presentan robustez frente a ruido y variabilidad interindividual.
- Permiten un ajuste fino de hiperparámetros (C , γ , kernel) que optimiza su desempeño [Mohebbi and Ghassemian \(2008\)](#).

En los últimos años, el aprendizaje profundo (Deep Learning) ha emergido como una alternativa poderosa para el análisis de señales biomédicas.

- Redes neuronales convolucionales (CNNs): son modelos diseñados para aprender características jerárquicas de los datos, empleando capas convolucionales que capturan patrones locales. En ECG, permiten detectar automáticamente formas de ondas relevantes.
- Redes recurrentes (RNN, LSTM, GRU): incorporan bucles en su arquitectura que permiten modelar dependencias temporales en series. Las LSTM y GRU, en particular, abordan el problema del desvanecimiento del gradiente y son efectivas para secuencias largas como las de intervalos RR [Petmezas et al. \(2021\)](#).
- Modelos híbridos: integran métricas tradicionales de HRV con arquitecturas profundas, intentando balancear precisión y explicabilidad clínica.

Aunque estas técnicas han mostrado un rendimiento superior en bases de datos extensas, su adopción clínica se ve limitada por dos factores: la falta de

interpretabilidad y la necesidad de grandes volúmenes de datos [Pourbabaee et al. \(2018\)](#).

2.6. El PhysioNet/Computing in Cardiology Challenge 2001

Un hito fundamental en el análisis computacional de arritmias fue el PhysioNet/Computing in Cardiology Challenge 2001 ([PhysioNet, 2001](#)), también conocido como Paroxysmal Atrial Fibrillation Prediction Challenge. El desafío se diseñó para evaluar si era posible anticipar la aparición de PAF a partir de registros de ECG obtenidos mediante monitoreo Holter de 24 horas.

El concurso se dividió en dos tareas: Evento 1 (screening), que buscaba clasificar a los sujetos en sanos o propensos a PAF, y Evento 2 (predicción), orientado a decidir cuál de dos segmentos consecutivos de 30 minutos precedía inmediatamente a un episodio de PAF. Para este fin, se dispuso de 100 pares de registros con anotaciones clínicas validadas.

El Evento 2 del Desafío PhysioNet 2001 se centra en la predicción de la PAF inminente en individuos identificados como de riesgo (grupo A). Específicamente, se busca determinar cuál de los dos registros de cada par de sujetos del grupo A precede inmediatamente un episodio de PAF. Los participantes deben clasificar exactamente uno de los registros de cada par como A (registro inmediatamente anterior a PAF) y el otro como N (registro no anterior a PAF). Cada par correctamente clasificado otorga un punto, y las puntuaciones ajustadas se obtienen restando 22 a la puntuación cruda, permitiendo un rango de 0 a 28 puntos. Este estudio trabajará en la realización de un modelo para el Evento 2 del Desafío.

Entre los enfoques más destacados en el **Evento 2** se encuentran:

- **Zong y Mark (2001)**: alcanzaron el mejor rendimiento no oficial con un 79 % de acierto (22/28), empleando la detección de complejos auriculares prematuros (CAPs) combinada con una regla de decisión ponderada [Zong et al. \(2001\)](#).
- **Schreier, Kastner y Marko (2001)**: ganadores oficiales del desafío con un 71 % de acierto (20/28), gracias a un modelo estadístico que integraba métricas de variabilidad de la frecuencia cardíaca (HRV) y características morfológicas

de la onda P [Schreier et al. \(2001\)](#).

- **Maier, Bauch y Dickhaus (2001):** exploraron parámetros clásicos y no lineales de HRV, mostrando que ciertos índices autonómicos podían discriminar a sujetos predispuestos a PAF, aunque con un desempeño limitado en predicción [Maier et al. \(2001\)](#).

El *Challenge 2001* fue decisivo porque mostró que, aun con técnicas relativamente simples de análisis de HRV y morfología de ondas, era posible anticipar la PAF con cierta precisión. Aunque los niveles de acierto no resultaron suficientes para la práctica clínica, el desafío sentó un precedente en la validación de métodos computacionales, estableciendo una base para el desarrollo posterior de enfoques de machine learning más avanzados.

2.7. Novedad de la Propuesta

A partir de la revisión anterior, se observa que:

Los métodos clásicos aportaron métricas fisiológicamente relevantes, pero con bajo poder predictivo.

El PhysioNet Challenge 2001 demostró la posibilidad de predecir episodios de PAF con algoritmos estadísticos y análisis de HRV, aunque con precisión imperfecta y mejorable.

Los métodos de aprendizaje automático, y en particular las SVM, ofrecen un equilibrio atractivo entre robustez, interpretabilidad y desempeño, siendo utilizados para conjuntos de datos de tamaño medio.

Los modelos modernos de deep learning representan la frontera actual, pero enfrentan limitaciones prácticas en términos de datos y explicabilidad.

El vacío identificado radica en la escasez de estudios recientes que apliquen un pipeline integral de procesamiento y clasificación mediante SVM optimizadas en la base PhysioNet Challenge 2001. Esto es especialmente importante, ya que esta base sigue siendo un estándar de referencia que concentra las dificultades inherentes a la predicción de PAF en condiciones reales.

La presente Tesis propone:

El diseño de un pipeline integral de preprocesamiento (filtrado, remuestreo, segmentación en ventanas y extracción de características HRV y morfológicas).

La implementación y optimización de un modelo de SVM como clasificador principal, ajustando sus parámetros mediante búsqueda sistemática.

La validación en la base PhysioNet Challenge 2001, lo que permite comparar resultados con los de estudios históricos (Zong, Schreier, Maier, Chesnokov) y evaluar la vigencia de las SVM frente a enfoques modernos.

De esta forma, este trabajo no solo replica metodologías previas, sino que ofrece un marco actualizado que busca mejorar la precisión en la predicción de PAF, con potencial impacto en la detección temprana y prevención de complicaciones clínicas.

Capítulo 3

Objetivos y Actividades

3.1. Objetivo General

Desarrollar un modelo de aprendizaje automático basado en Máquinas de Vectores de Soporte (SVM) para la predicción de episodios inminentes de Fibrilación Auricular Paroxística a partir del análisis de señales de electrocardiograma (ECG).

3.2. Objetivos Específicos

- Estudiar el contexto y las conclusiones del Evento 2 del Desafío PhysioNet/Computing in Cardiology Challenge 2001 como un marco histórico y un escenario de evaluación para predecir Fibrilación Auricular Paroxística.
- Analizar la efectividad del enfoque propuesto utilizando el conjunto de datos del desafío y hacer una comparación con resultados anteriores.
- Examinar las repercusiones clínicas de la detección anticipada de Fibrilación Auricular Paroxística y el potencial de las técnicas modernas en la atención diaria a pacientes.
- Cuantificar el rendimiento del modelo propuesto para la predicción de Fibrilación Auricular Paroxística inminente, utilizando la métrica de Puntuación Oficial definida en el Evento 2 del PhysioNet Challenge 2001, y comparar este resultado con las puntuaciones obtenidas por los participantes del desafío.

Capítulo 4

Metodología

Esta sección describe la metodología utilizada en la presente investigación para abordar la predicción de la PAF, incluyendo el contexto del desafío que sirvió como base para la evaluación, la metodología de los ganadores históricos y, en detalle, la implementación propia.

4.1. Descripción de la base de datos

La base de datos utilizada corresponde al *PAF Prediction Challenge Database* del desafío PhysioNet 2001 [PhysioNet \(2001\)](#). Está compuesta por pares de registros de 30 minutos de duración, obtenidos de un mismo sujeto, con las siguientes características:

- **Registros p:** 25 pares de ECG (50 registros en total) provenientes de pacientes con diagnóstico de PAF).
 - El registro impar corresponde a un período alejado de cualquier episodio de PAF (≥ 45 minutos antes y después sin arritmia).
 - El registro par corresponde a los 30 minutos inmediatamente anteriores al inicio de un episodio de PAF.
- **Registros n:** 25 pares de ECG (50 registros en total) provenientes de sujetos sin PAF documentado. Ambos registros del par se seleccionan en momentos aleatorios de la señal, sin presencia de arritmia.
- **Conjunto de prueba (t):** 50 pares de ECG (100 registros en total) mantiene la misma estructura en pares consecutivos, incluyendo tanto sujetos con PAF

como sujetos sin PAF, aunque sin indicación explícita de cuál corresponde a cada grupo.


En este trabajo se utilizaron exclusivamente los registros **p** para el entrenamiento, dado que el objetivo del **Evento 2** es determinar, dentro de cada par de un paciente con PAF, cuál de los dos registros corresponde al período inmediatamente previo a un episodio, el registro par (pre-PAF) se considera como clase **A**, mientras que el registro impar (alejado de PAF) se considera como clase **N**. Para la construcción del conjunto de entrenamiento, se definió la etiqueta de clase y_i según la siguiente convención:

$$y_i = \begin{cases} 1, & \text{si el registro es par, es decir, corresponde al período} \\ & \text{inmediatamente previo a un episodio de PAF (pre-PAF)} \\ 0, & \text{si el registro es impar, correspondiente a un período alejado} \\ & \text{del episodio de PAF (normal o estable)} \end{cases}$$

donde $i = 1, 2, \dots, 50$ representa el índice de cada registro individual del grupo **p**, considerando que cada paciente aporta un par de registros consecutivos, correspondientes respectivamente a los estados *normal* y *pre-PAF*.

En este trabajo se desarrolló una implementación propia para abordar el Evento 2 del Desafío PhysioNet 2001. El enfoque adoptado se basó en la extracción de un conjunto amplio de características y en el uso de Máquinas de Vectores de Soporte. El objetivo del modelo propuesto es, por tanto, predecir correctamente cuál de los dos registros de cada par pertenece a la clase **A**, es decir, aquel que antecede de manera inmediata al inicio de un episodio de Fibrilación Auricular Paroxística.

A continuación, en la Figura (4.1.1) se describen los pasos utilizados en la metodología:

**Figura 4.1.1: Guía de trabajo.**

4.1.1. Preprocesamiento y segmentación en ventanas

Inicialmente, las señales de ECG fueron sometidas a un **downsampling de 128 Hz a 64 Hz**, con el fin de reducir la carga computacional manteniendo suficiente resolución sin pérdida significativa de morfología para el análisis de la actividad cardíaca. La Figura (4.1.2) muestra una señal en particular de ECG con el cambio de resolución.




Figura 4.1.2: Comparación de la señal ECG a 128 Hz y 64 Hz.

Posteriormente, cada señal ECG de 30 minutos fue segmentada en **ventanas deslizantes de 5 minutos con 50 % de solapamiento** (equivalentes a 38.400 muestras por ventana). La elección de este intervalo se fundamenta en que los análisis de variabilidad de la frecuencia cardíaca (VFC) en el dominio del tiempo y la frecuencia muestran mayor estabilidad y reproducibilidad cuando se emplean periodos de cinco minutos, lo cual constituye el estándar recomendado para análisis de corto plazo [Uryga et al. \(2025\)](#).

Dado que las características estadísticas de la señal ECG como la media, la varianza y la estructura espectral pueden variar a lo largo del tiempo, es necesario asumir una condición de cuasi-estacionaridad para aplicar métricas de VFC de forma consistente [Chen et al. \(2024\)](#). Al segmentar el registro en ventanas de 5 minutos, esta condición se aproxima adecuadamente dentro de cada intervalo, permitiendo extraer información fisiológica representativa del estado autonómico en ese periodo. Además, esta duración

es ampliamente utilizada en estudios de VFC y en trabajos previos relacionados con la predicción de PAF [Castro et al. \(2021\)](#).

Se empleó un esquema de ventanas deslizantes con un solapamiento del 50 %, esto implica que cada nueva ventana comienza 2.5 minutos después de la anterior, generando **11 ventanas por cada señal de 30 minutos**, como se puede observar en la Figura (4.1.3):




Figura 4.1.3: Segmentación temporal de la señal ECG mediante ventanas de 5 minutos con solapamiento del 50 %, generando 11 ventanas por registro de 30 minutos. El desplazamiento vertical se utiliza únicamente con fines ilustrativos.

El uso de solapamiento permite capturar cambios graduales, lo cual es particularmente relevante en las fases previas a un episodio de fibrilación auricular. Este enfoque mejora la sensibilidad frente a patrones sutiles y progresivos que preceden el evento, sin sacrificar consistencia entre sujetos.

Segmentación de ECG (Ventanas Deslizantes con 50% de Solapamiento)

```
import numpy as np
from scipy.signal import resample

# Ruta de los datos
DATA_DIR = 'C:/Test/'

# Cargar señal ECG del primer canal
signal = np.loadtxt(DATA_DIR + 'p01.txt', usecols=(0,))

# Downsampling de 128 Hz a 64 Hz
n_samples = int(len(signal) * 64 / 128)
sig_64Hz = resample(signal, n_samples)

# Tamaño de ventana (5 minutos) y paso (50% = 2.5 min)
FS = 64
WINDOW_SAMPLES = 5 * 60 * FS          # 5 minutos
STEP = WINDOW_SAMPLES // 2            # 50% solapamiento

# Generar ventanas deslizantes
ventanas = []
for start in range(0, len(sig_64Hz) - WINDOW_SAMPLES + 1, STEP):
    end = start + WINDOW_SAMPLES
    ventana = sig_64Hz[start:end]
    ventanas.append(ventana)

print(f"Número de ventanas generadas: {len(ventanas)}")
# Para un registro de 30 minutos, esto produce 11 ventanas
```

4.1.2. Detección de Peaks R y Delineación de Ondas

Para cada segmento de 5 minutos, se utilizó la biblioteca `neurokit2` [Makowski et al. \(2021\)](#) para detectar los peaks R del complejo QRS, aplicando corrección de artefactos, y para delinear las ondas P, QRS y T utilizando la transformada wavelet discreta (DWT), lo que permite analizar morfología en señales no estacionarias.

NeuroKit2 es una biblioteca de Python orientada al análisis y procesamiento de señales fisiológicas. Permite realizar la limpieza de registros ECG, la detección de picos R y la delineación de las ondas P, QRS y T, que constituyen los principales componentes morfológicos del ECG.

Los picos R representan los puntos de máxima amplitud dentro del complejo QRS y son esenciales para el cálculo de los intervalos RR y de la variabilidad de la frecuencia cardíaca. Además, la biblioteca incluye rutinas para la corrección de artefactos y la evaluación de la calidad de la señal, lo que garantiza la fiabilidad de las métricas obtenidas.

El siguiente algoritmo resume las etapas implementadas por NeuroKit2 durante el procesamiento de una señal ECG, desde la limpieza inicial hasta la obtención de las características de HRV empleadas posteriormente en la clasificación.

Algorithm 1 Procesamiento de señal ECG con NeuroKit2

Entradas: señal ECG $s(t)$; frecuencia de muestreo f_s ; configuración cfg .
Salidas: intervalos RR; índices HRV (tiempo, frecuencia, no lineal); ondas P–QRS–T; calidad $\mathcal{Q}$.

1. **Limpieza:** $\text{ecg_clean} \leftarrow \text{ecg_clean}(\mathbf{e}, f_s, \text{method} = \text{cfg.clean})$
2. **Picos R:** $(\text{signals}, \text{info}) \leftarrow \text{ecg_peaks}(\text{ecg_clean}, f_s)$
3. **Delineación:** $\text{waves} \leftarrow \text{ecg_delineate}(\text{ecg_clean}, \text{info}, f_s, \text{method} = \text{cfg.delineate})$
4. **Intervalos RR:** $\text{rr} \leftarrow \text{signal_interval}(\text{info}['\text{ECG_R_Peaks}'], f_s)$
5. **HRV:**
 $\text{hrv_time} \leftarrow \text{hrv_time}(\text{rr}); \text{hrv_freq} \leftarrow \text{hrv_frequency}(\text{rr}, f_s); \text{hrv_nonlin} \leftarrow \text{hrv_nonlinear}(\text{rr})$
6. **Calidad:** $\mathcal{Q} \leftarrow \text{ecg_quality}(\text{ecg_clean}, f_s)$
7. **Agregación:** $\text{features} \leftarrow \text{combine_features}(\text{signals}, \text{info}, \text{waves}, \text{hrv_*}, \mathcal{Q})$
8. **Retornar:** $\text{return rr, hrv_*, waves, } \mathcal{Q}, \text{features}$

La delineación de las ondas P, QRS y T es un proceso crítico para extraer características morfológicas y temporales de la señal de ECG y esto se puede realizar gracias a la DWT.

La **Transformada Wavelet Discreta (DWT)** permite expresar una señal $s(t)$ como una combinación de versiones escaladas y desplazadas de una *wavelet madre*

$\psi(t)$, según:

$$s(t) = \sum_{j,k} c_{j,k} \psi_{j,k}(t), \quad \text{donde} \quad \psi_{j,k}(t) = 2^{-j/2} \psi(2^{-j}t - k).$$

En esta formulación:

- $s(t)$ es la señal original, en este caso, el registro de ECG.
- $\psi(t)$ es la *wavelet madre*, una función base de corta duración y energía finita, utilizada para generar toda la familia de funciones analíticas.
- $\psi_{j,k}(t)$ representa una copia escalada y desplazada de la wavelet madre: el parámetro j controla la *escala* (frecuencia analizada), y k su *posición temporal*. Escalas pequeñas (j bajo) capturan cambios rápidos de alta frecuencia, mientras que escalas grandes (j alto) describen variaciones lentas de baja frecuencia.
- El factor $2^{-j/2}$ mantiene la energía constante al cambiar de escala.
- Los coeficientes $c_{j,k}$ cuantifican cuánto se parece la señal $s(t)$ a la función $\psi_{j,k}(t)$ en ese instante y escala. En la práctica, estos coeficientes se dividen en dos grupos:
 - Los **coeficientes de aproximación** $a_J[k]$, obtenidos con la *función de escalado* $\phi_{J,k}(t)$, describen las componentes de baja frecuencia o la tendencia general de la señal.
 - Los **coeficientes de detalle** $d_j[k]$, asociados a la *wavelet* $\psi_{j,k}(t)$, capturan las variaciones rápidas o transitorias.

La reconstrucción completa de la señal se obtiene combinando las aproximaciones y los detalles en cada nivel de descomposición:

$$s(t) = A_J(t) + \sum_{j=1}^J D_j(t),$$

donde $A_J(t) = \sum_k a_J[k] \phi_{J,k}(t)$ representa la tendencia suave (ondas P y T), y $D_j(t) = \sum_k d_j[k] \psi_{j,k}(t)$ modela los eventos rápidos (complejo QRS). Así, cada nivel j captura una franja específica de frecuencias, permitiendo analizar la señal con resolución tanto temporal como frecuencial [Percival and Walden \(2000\)](#); [Chui \(1992\)](#).

En el contexto del ECG, esta descomposición permite identificar con precisión los

puntos de referencia como los peaks P, R y T al analizar la energía de los coeficientes en diferentes niveles. En particular, los coeficientes de detalle intermedios (d_3-d_5) concentran la energía del complejo QRS, caracterizado por transiciones bruscas de alta frecuencia. Al detectar los máximos locales de estos coeficientes y analizar sus cruces por cero, es posible estimar la posición temporal exacta de los picos R y, por extensión, de los puntos de inicio y fin de las ondas P y T. Este procedimiento, implementado en NeuroKit2 mediante la función `ecg_delineate()`, combina la información multiescala de los niveles de detalle y aproximación, permitiendo una delineación automática y robusta incluso en señales ruidosas.

En nuestro caso, NeuroKit2 emplea la wavelet **Daubechies 6 (db6)**, adecuada para ECG por su similitud con la morfología del complejo QRS y su buena localización temporal. Los coeficientes de detalle en niveles intermedios (d_3-d_5) abarcan el rango de 2 a 16 Hz, que corresponde a la actividad principal del ECG: el nivel d_3 concentra la mayor energía del complejo QRS, el nivel d_4 representa las transiciones del QRS y parte de la onda T, mientras que d_5 captura las ondas P y T de baja frecuencia. Esta descomposición multiescala permite una reconstrucción precisa de la señal y la identificación robusta de los puntos fiduciales, facilitando el análisis morfológico de las ondas P, QRS y T (Park et al., 2017).

En la Figura (4.1.4) se muestra un ejemplo del ECG correspondiente a p08, en el que se observan la detección de peaks R y delineación de ondas. Por otro lado, la Figura (4.1.5) despliega la descomposición de las frecuencias del ECG p08 mediante la metodología DWT. Ambas características fueron obtenidas a través del algoritmo Neurokit2.




Figura 4.1.4: Ejemplo Detección de Peaks R y Delineación de Ondas con Neurokit2




Figura 4.1.5: Descomposición del ECG p08 utilizando DWT

Segmentación de ECG

```
import neurokit2 as nk

# Seleccionamos la primera ventana de 5 min como ejemplo
segmento = ventanas[0]

# Detectar peaks R con corrección de artefactos
ecg_cleaned, rpeaks = nk.ecg_peaks(segmento, sampling_rate=64,
    correct_artifacts=True)
picos_R = rpeaks['ECG_R_Peaks']

# Delineación de ondas P, QRS y T usando DWT
delineado = nk.ecg_delineate(segmento, rpeaks,
    sampling_rate=64, method='dwt')
ondas = delineado[1]
p_onsets = ondas['ECG_P_Onsets']
p_offsets = ondas['ECG_P_Offsets']
```

4.1.3. Cálculo de Características

La Variabilidad de la Frecuencia Cardíaca (VFC) se define como las fluctuaciones latido a latido en la frecuencia cardíaca, específicamente las variaciones en los intervalos RR. Una VFC elevada generalmente indica un corazón sano y una función autónoma eficiente, mientras que una VFC reducida puede señalar posibles problemas de salud, como estrés, ansiedad o enfermedades cardiovasculares.

La onda P representa la despolarización auricular. Su morfología se considera un marcador no invasivo de la predisposición a la FA, reflejando la conducción auricular y el remodelado estructural.

Se computó la duración media y la desviación estándar de la onda P. La prolongación de la duración de la onda P se correlaciona con una velocidad de conducción auricular más lenta, lo que sugiere fibrosis auricular, un factor asociado con la FA. La morfología anormal de la onda P, que incluye características como un ensanchamiento, mayor

complejidad, rugosidad o bifasicidad, es un predictor independiente del desarrollo de FA. La desviación de la duración normal (típicamente inferior a 0.12 segundos) y los cambios en la desviación estándar pueden indicar patología auricular y un aumento del riesgo de PAF.

La combinación de las características morfológicas de la onda P con las métricas de VFC proporciona una imagen más completa de la condición cardíaca. Mientras que la VFC refleja el tono autonómico, la morfología de la onda P indica directamente la salud del sustrato auricular. Este enfoque multifacético mejora la capacidad del modelo para capturar diversos indicadores pre-PAF, aprovechando la información complementaria de ambos tipos de características.

Finalmente, las características extraídas de cada una de las once ventanas de 5 minutos fueron concatenadas para formar un único vector representativo por cada grabación. Este vector de características aplanado consolida toda la información temporal y morfológica en un formato adecuado para su uso en modelos de aprendizaje automático.

A partir de los peaks R y las ondas delineadas se calcularon las siguientes métricas del ritmo cardíaco y de la onda P, utilizando NeuroKit2 [Ebrahimzadeh et al. \(2018\)](#):

- **VFC en dominio temporal** (observa cómo varía el tiempo entre latidos consecutivos):
 - **Media de intervalos RR**: el tiempo promedio entre un latido y el siguiente.
 - **Desviación estándar de intervalos RR (SDNN)**: cuánto varía el tiempo entre latidos; valores mayores indican más variabilidad.
 - **RMSSD**: mide los cambios rápidos de un latido al siguiente; valores más altos reflejan que el corazón puede ajustarse rápido a cambios en el cuerpo.
 - **pNN50**: porcentaje de latidos que cambian más de 50 milisegundos respecto al anterior; ayuda a ver si el corazón responde bien a pequeñas variaciones.
- **VFC en dominio frecuencial** (mira patrones de ritmo según la velocidad de los cambios):
 - **Baja frecuencia (LF)**: cambios lentos en el ritmo cardíaco; están

relacionados con estrés o actividad general del cuerpo.

- **Alta frecuencia (HF)**: cambios rápidos, normalmente asociados a la respiración y a relajación.
- **VFC no lineal** (explora patrones más complejos y difíciles de predecir):
 - **Entropía y métricas de complejidad**: nos dicen cuán impredecible o irregular es el ritmo del corazón; valores más altos muestran un ritmo más dinámico y flexible.
- **Onda P** (relacionada con la actividad de las aurículas del corazón):
 - **Duración media y desviación estándar**: ondas P más largas pueden indicar que las aurículas tardan más en activarse, lo que está asociado a mayor riesgo de PAF.

La Tabla 4.1.1 muestra un ejemplo representativo del **vector de características** obtenido para la **ventana 1** de varios registros del grupo **p**. Cada fila corresponde a una métrica de variabilidad de la frecuencia cardíaca (HRV) calculada sobre intervalos NN (corresponden a los tiempos entre dos latidos cardíacos consecutivos considerados normales, es decir, entre picos **R** válidos del complejo QRS en el ECG.), mientras que cada columna representa un registro diferente. Se observa cómo los valores varían entre sujetos, reflejando diferencias en la dinámica cardíaca y en la regularidad de los intervalos entre latidos.

Cuadro 4.1.1: Ejemplo comparativo de vectores de características HRV (ventana 1) para varios registros del grupo p. Cada fila representa una métrica extraída del ECG en una ventana de 5 minutos.

Característica	p01	p02	p03	p04	p...	p50
HRV_MeanNN_w1	942.33	742.94	653.07	717.75	...	957.76
HRV_SDNN_w1	1390.83	9.21	10.57	13.96	...	143.75
HRV_SDANN1_w1	261.74	4.74	6.65	9.70	...	7.10
HRV_SDNNI1_w1	836.34	8.16	8.22	10.17	...	113.61
HRV_RMSSD_w1	1355.00	10.23	8.56	12.40	...	243.62
HRV_SDSO_w1	1357.15	10.24	8.57	12.41	...	244.01
HRV_CVNN_w1	1.48	0.01	0.02	0.02	...	0.15
HRV_CVSD_w1	1.44	0.01	0.01	0.02	...	0.25
HRV_MedianNN_w1	773.44	742.19	648.44	718.75	...	968.75
HRV_MadNN_w1	23.17	11.58	11.58	11.58	...	23.17
HRV_MCVNN_w1	0.03	0.02	0.02	0.02	...	0.02
HRV_IQRNN_w1	39.06	15.62	7.81	15.63	...	31.25
HRV_SDRMSSD_w1	1.03	0.90	1.23	1.13	...	0.59
HRV_Prc20NN_w1	757.81	734.38	648.44	710.94	...	953.13
HRV_Prc80NN_w1	796.88	750.00	656.25	726.56	...	992.19
HRV_pNN50_w1	2.84	0.00	0.66	0.72	...	32.37
HRV_pNN20_w1	18.93	3.47	1.97	1.20	...	39.42
HRV_MinNN_w1	679.69	718.75	609.38	664.06	...	570.31
HRV_MaxNN_w1	13742.19	773.44	695.31	828.13	...	1250.00
HRV_HTI_w1	7.04	2.78	2.66	3.47	...	5.57




Figura 4.1.6: Gráfico comparativo de una característica entre los dos grupos

4.1.4. Selección de Características

Para reducir la dimensionalidad y conservar únicamente la información más relevante se aplicó una selección supervisada de características mediante **SelectKBest**. Este método forma parte del módulo de selección de características del paquete *scikit-learn* [Pedregosa et al. \(2011\)](#) y permite evaluar la relevancia de cada variable de forma independiente. En este estudio, se utilizó `f_classif` como función de puntuación, la cual implementa la prueba estadística *ANOVA F-value* para comparar la separación entre clases. De este modo, cada característica recibe un puntaje proporcional a su capacidad discriminante: cuanto mayor es el valor F, mayor es la diferencia estadística entre las clases.

Tras evaluar modelos entrenados con 40, 60, 80 y 100 características, se determinó que la selección de **40 características** proporciona el mejor equilibrio entre rendimiento predictivo y estabilidad. De esta forma, se conservan únicamente las 40 variables más relevantes fisiológica y estadísticamente, lo que permite mejorar la generalización del modelo y reducir el riesgo de sobreajuste.

Cálculo de Características

```
# Calcular métricas de VFC
hrv_time    = nk.hrv_time(picos_R, sampling_rate=64)
hrv_freq    = nk.hrv_frequency(picos_R, sampling_rate=64)
hrv_nonlinear = nk.hrv_nonlinear(picos_R, sampling_rate=64)

# Combinar todas las características
features = {**hrv_time, **hrv_freq, **hrv_nonlinear}

# Agregar duración de onda P
features['P_Duration_Mean'] = np.nanmean(p_duration)
features['P_Duration_STD']  = np.nanstd(p_duration)
```

4.1.5. Máquinas de Vectores de Soporte (SVM)

Las Máquinas de Vectores de Soporte (SVM, por sus siglas en inglés) son algoritmos de aprendizaje supervisado ampliamente utilizados en clasificación y regresión. Su origen se remonta al trabajo de [Cortes and Vapnik \(1995\)](#), donde se planteó un modelo capaz de encontrar un hiperplano óptimo que separara dos clases maximizando el margen entre ellas. En contraste con otros métodos estadísticos, las SVM buscan no solo separar los datos, sino hacerlo con la mayor distancia posible a los puntos más cercanos de cada clase, conocidos como *vectores de soporte*. Estos vectores son los ejemplos críticos que determinan la posición del hiperplano y, por lo tanto, el modelo final [Jakkula \(2006\)](#).

Formulación matemática

En este trabajo se utilizó una **SVM** para la clasificación binaria de los registros del grupo **p** en el **Evento 2** del Desafío PhysioNet 2001. Cada registro se representó mediante un vector de características $\mathbf{x}_i \in \mathbb{R}^m$, compuesto por métricas de variabilidad de la frecuencia cardíaca (HRV) y rasgos morfológicos del ECG, obtenidos en once ventanas consecutivas de cinco minutos.

A cada registro se le asignó una etiqueta de clase binaria y_i , definida como:

$$y_i = \begin{cases} 1, & \text{si el registro es par (pre-PAF)} \\ 0, & \text{si el registro es impar (lejano al PAF)} \end{cases} \quad \text{con } i = 1, 2, \dots, 50$$

La SVM busca el hiperplano que maximiza el margen entre las dos clases, definido por:

$$\mathbf{w}^T \mathbf{x} + b = 0,$$

donde $\mathbf{w}$ es el vector de pesos y b el término de sesgo. El problema de optimización se formula como:

$$\min_{\mathbf{w}, b, \xi_i} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i,$$

sujeto a:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, N$$

donde C controla el equilibrio entre la complejidad del modelo y el número de errores de clasificación permitidos [Fletcher \(2009\)](#).

Dado que las fronteras de decisión en este problema no son lineales, se aplicó el **truco del kernel** mediante la **Función de Base Radial (RBF)**.

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

El *truco del kernel* [Soman et al. \(2009\)](#); [Schölkopf and Smola \(2002\)](#) consiste en que, en lugar de calcular explícitamente una transformación no lineal $\varphi(\mathbf{x})$ que mapea los vectores de entrada a un espacio de características de alta dimensión H , se define una función de núcleo $K(\mathbf{x}_i, \mathbf{x}_j)$ que equivale al producto interno entre las imágenes de dichos vectores en ese nuevo espacio:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \varphi(\mathbf{x}_i)^T \varphi(\mathbf{x}_j)$$

De esta forma, las operaciones de producto interno necesarias para la SVM se realizan de manera implícita, sin necesidad de conocer o calcular directamente la transformación $\varphi(\mathbf{x})$. Esta estrategia permite que el modelo aprenda fronteras de

decisión no lineales en el espacio original de los datos, a la vez que mantiene un costo computacional bajo.

En términos geométricos, $\varphi(\mathbf{x})$ proyecta los vectores originales $\mathbf{x} \in \mathbb{R}^m$ a un espacio de mayor dimensión donde las clases resultan linealmente separables. Por ejemplo, el **kernel de base radial (RBF)**:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

La elección del kernel **RBF** se debe a su capacidad para modelar relaciones no lineales complejas entre las características fisiológicas, sin requerir un ajuste extenso de parámetros ni un conocimiento previo de la distribución de los datos. A diferencia del kernel lineal, que asume separabilidad directa en el espacio original, el RBF proyecta los vectores de características a un espacio de dimensión infinita, permitiendo que la SVM capture patrones sutiles asociados a la dinámica del ritmo cardíaco y a las transiciones previas al episodio de fibrilación auricular. El RBF ofrece un equilibrio robusto entre flexibilidad, capacidad de generalización y eficiencia computacional, siendo además el kernel más utilizado en aplicaciones biomédicas [Toledo-Pérez et al. \(2019\)](#).




Figura 4.1.7: Transformación no lineal mediante el truco del kernel en una SVM

Como se observa en la Figura 4.1.7, la transformación $\varphi(\mathbf{x})$ permite proyectar los datos en un espacio de mayor dimensión donde se obtiene una frontera de decisión lineal, facilitando la separación de clases que en el espacio original no era posible.

Aplicación en este estudio

Para la clasificación de registros de ECG, las SVM resultan especialmente adecuadas debido a la naturaleza no lineal y compleja de las características extraídas, como la variabilidad de la frecuencia cardíaca y la morfología de la onda P [Ebrahimzadeh et al. \(2018\)](#). En este trabajo, se implementó un pipeline de procesamiento que incluyó:

- **Imputación y normalización:** se imputaron valores faltantes mediante la media (`SimpleImputer`) y se normalizaron las características utilizando `StandardScaler`, asegurando que todas las variables compartieran la misma escala.
- **Optimización de hiperparámetros:** se realizó una búsqueda exhaustiva

mediante **GridSearchCV**, evaluando distintas combinaciones de los hiperparámetros C y γ del kernel RBF. La evaluación se realizó utilizando **validación cruzada estratificada 5×2** (**RepeatedStratifiedKFold**), con **F1-score** como métrica de desempeño. Este esquema permite una estimación más estable del rendimiento y una menor probabilidad de sobreajuste.

- **Clasificación binaria:** el modelo final distinguió entre registros pertenecientes al grupo normal y sujetos con riesgo inminente de fibrilación auricular. La configuración obtenida mediante validación cruzada fue posteriormente reentrenada con el conjunto de datos completo para generar las predicciones finales.

SVM

```
# --- Dividir datos y preprocesar ---
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.impute import SimpleImputer
from sklearn.svm import SVC

# Separar características y etiquetas
X_train, X_val, y_train, y_val = train_test_split(
    X, y, test_size=0.25, random_state=42, stratify=y
)

# Imputar valores faltantes y escalar
imputer = SimpleImputer(strategy='mean').fit(X_train)
scaler = StandardScaler().fit(imputer.transform(X_train))
X_train_scaled = scaler.transform(imputer.transform(X_train))
X_val_scaled = scaler.transform(imputer.transform(X_val))

# Entrenar SVM básico
svm_model = SVC(probability=True, random_state=42,
kernel='rbf', C=1, gamma='scale')
svm_model.fit(X_train_scaled, y_train)
```

4.1.6. Optimización de Hiperparámetros: GridSearchCV, Optuna e Hyperopt

Para la optimización de los hiperparámetros del modelo se evaluaron tres enfoques: **GridSearchCV**, **Optuna** y **Hyperopt**. El uso de distintos métodos de optimización permitió comparar tanto la estabilidad del rendimiento como el costo computacional asociado a cada estrategia.

GridSearchCV realiza una búsqueda exhaustiva sobre una cuadrícula fija de hiperparámetros, evaluando cada combinación mediante validación cruzada. Si bien este método puede ser computacionalmente más costoso, ofrece resultados consistentes y reproducibles al explorar el espacio de soluciones de manera sistemática.

Optuna y Hyperopt, por otro lado, implementan estrategias de optimización basada en búsqueda inteligente (bayesiana y TPE, respectivamente), lo que les permite explorar el espacio de hiperparámetros de forma más eficiente. Estos métodos reducen el tiempo de búsqueda, pero pueden mostrar una mayor variabilidad en los resultados, especialmente cuando el conjunto de entrenamiento es reducido.

En todos los métodos se utilizó validación cruzada estratificada para reducir el sobreajuste y asegurar la generalización del modelo. Luego de la búsqueda, el mejor modelo de cada método fue reentrenado utilizando el conjunto de datos completo.

La Tabla 4.1.2 presenta la comparación entre los tres enfoques y diferenciando entre el uso y no uso de ventanas solapadas.

Cuadro 4.1.2: Comparación de métodos de optimización de hiperparámetros con 30 semillas. Se reporta la precisión del Grupo A (promedio $\pm$ desviación estándar) en el Evento 2.

Método	Overlap	Precisión Grupo A	Tiempo (aprox.)
GridSearchCV	Sí	$0,696 \pm 0,019$	7 min 37 s
GridSearchCV	No	$0,596 \pm 0,045$	4 min 28 s
Optuna	Sí	$0,629 \pm 0,042$	7 min 03 s
Optuna	No	$0,557 \pm 0,054$	3 min 51 s
Hyperopt	Sí	$0,589 \pm 0,078$	7 min 05 s
Hyperopt	No	$0,539 \pm 0,074$	3 min 47 s

Los resultados muestran que **GridSearchCV con solapamiento entre ventanas obtiene el mejor desempeño promedio**, logrando una precisión del 69.6 % en el Grupo A. Esto sugiere que, en este contexto, la búsqueda exhaustiva combinada con una representación temporal más densa de la señal (ventanas deslizantes con 50 % de solapamiento) captura de manera más robusta las dinámicas previas al evento de fibrilación auricular.

Optuna y Hyperopt reducen el tiempo de optimización al explorar el espacio de hiperparámetros de manera adaptativa; sin embargo, presentan una mayor variabilidad en el rendimiento, especialmente sin solapamiento. Esto refuerza la importancia de incorporar información temporal fina en la etapa de extracción de características y de utilizar estrategias de búsqueda que mantengan estabilidad en modelos con datos fisiológicos de alta variabilidad intersujeto.

Validación

```
# --- Optimización de hiperparámetros con GridSearchCV ---
from sklearn.model_selection import GridSearchCV, RepeatedStratifiedKFold
from sklearn.svm import SVC
from sklearn.metrics import f1_score

# Definir cuadrícula de parámetros (ejemplo simplificado)
param_grid = {
    "C": [1e-3, 1e-2, 1e-1, 1, 10, 100, 1e3],
    "gamma": [1e-4, 1e-3, 1e-2, 1e-1, 1, "scale"],
    "kernel": ["rbf"],
    "class_weight": ["balanced", None]
}

# Validación cruzada 5x2
cv = RepeatedStratifiedKFold(n_splits=5, n_repeats=2, random_state=seed)

# GridSearch con F1 como métrica
grid = GridSearchCV(
    SVC(kernel='rbf', probability=True, random_state=seed),
    param_grid,
    cv=cv,
    scoring='f1',
    n_jobs=-1
)
grid.fit(X_train_scaled, y_train)

# Resultados
print("Mejores parámetros:", grid.best_params_)
print("F1 en validación:",
      f1_score(y_val, grid.best_estimator_.predict(X_val_scaled)))
```

4.1.7. Generación de Predicciones para el Desafío

Para el Evento 2 del desafío, la tarea era clasificar pares de registros (t_{XX} y t_{XX+1}) como 'A' (precediendo PAF) o 'N' (no precediendo PAF). El modelo entrenado generó probabilidades de predicción para cada registro individual. Luego, para cada par, se compararon las probabilidades de que cada registro precediera a la PAF, asignando 'A' al registro con mayor probabilidad y 'N' al otro.

Capítulo 5

Resultados

Esta sección presenta los resultados obtenidos en la presente investigación y los compara con los puntos de referencia históricos. Además, se analizan las limitaciones de los métodos disponibles en 2001 y se revisan los avances en el análisis de señales biomédicas que justifican la aplicación de métodos modernos.

5.1. Resultados Obtenidos

Para evaluar la efectividad del modelo desarrollado en esta investigación, se procedió a comparar su desempeño directamente con los resultados obtenidos por los participantes en el Evento 2 del PhysioNet/Computing in Cardiology Challenge 2001. La Tabla 5.1.1 presenta la puntuación oficial (número de pares de registros clasificados correctamente sobre un total de 28 del Grupo A) de los principales participantes, junto con el resultado alcanzado por el modelo propuesto en este trabajo.

Cuadro 5.1.1: Comparativa de resultados para el Evento 2 del PhysioNet Challenge 2001.

Pos.	Puntuación	Precisión	Participante / Afiliación
1	22/28	79 %	W Zong and RG Mark <i>Harvard-MIT Division of Health Sciences and Technology, USA (no oficial)</i>
2	21/28	75 %	Maximiliano Concha <i>Universidad de Concepción (Presente Tesis)</i>
3	20/28	71 %	G Schreier, P Kastner, and W Marko <i>Austrian Research Centers Seibersdorf, Austria</i>
4	19/28	68 %	P de Chazal and C Heneghan <i>University of New South Wales, Australia</i>
	19/28	68 %	C Maier, M Bauch, and H Dickhaus <i>University of Applied Sciences, Heilbronn, Germany</i>
5	18/28	64 %	KS Lynn and HD Chiang <i>Cornell University, USA</i>
6	17/28	61 %	P Langley et al. <i>Freeman Hospital, Newcastle upon Tyne, UK</i>
	17/28	61 %	D Gamberger and T Smuc <i>Rudjer Boskovic Institute, Croatia</i>
7	16/28	57 %	CC Yang <i>National Yang-Ming University, Taiwan</i>
	16/28	57 %	R Sweeney et al. <i>Guidant Corp., USA</i>
8	15/28	54 %	L Almarro <i>UPV, Valencia, Spain</i>

El resultado obtenido en esta investigación, una puntuación de 21/28 (equivalente a un 75 % de precisión en el contexto de los 28 pares evaluados), demuestra la viabilidad de aplicar métodos de aprendizaje automático para la predicción de la Fibrilación Auricular Paroxística en el contexto del Desafío PhysioNet 2001. Este rendimiento,

si bien no supera el resultado ajustado de 22/28 de [Zong and Mark \(2001\)](#), es muy competitivo y significativo para una implementación independiente. Además, supera el desempeño de los ganadores oficiales del evento, quienes alcanzaron una puntuación de 20/28 [Schreier et al. \(2001\)](#).

La metodología de Zong y Mark se centró en la detección y ponderación de complejos auriculares prematuros (CAPs), una característica muy específica y basada en el conocimiento experto del dominio [Zong and Mark \(2001\)](#). En contraste, la presente investigación adoptó un enfoque más amplio en la extracción de características, incluyendo la variabilidad de la frecuencia cardíaca (VFC) y la morfología de la onda P, extraídas de múltiples ventanas temporales. Esta estrategia busca capturar patrones más complejos y sutiles en la señal de ECG que podrían indicar la proximidad de un episodio de PAF.

Limitaciones del Presente Estudio

Una limitación inherente a este estudio es el tamaño del conjunto de datos disponible para el entrenamiento y la evaluación. El Desafío PhysioNet 2001 proporciona una base de datos total de 100 pares de grabaciones de ECG (es decir, 200 segmentos individuales). Sin embargo, esta base de datos se divide equitativamente en un conjunto de aprendizaje y un conjunto de prueba, lo que significa que solo 50 pares (100 segmentos) están disponibles para el entrenamiento del modelo.

Para los métodos de aprendizaje automático, y especialmente para las arquitecturas más complejas que podrían extraer patrones más profundos, un conjunto de datos más grande y diverso sería ideal para mejorar la capacidad de generalización y el rendimiento. La cantidad de datos de entrenamiento puede influir directamente en la capacidad del modelo para aprender representaciones robustas y evitar el sobreajuste, lo que sugiere que un mayor número de ejemplos podría conducir a mejoras adicionales en la precisión.

Capítulo 6

Discusión

La capacidad de predecir PAF antes de su inicio es de gran valor clínico. Al anticipar estos episodios, los médicos pueden implementar estrategias preventivas, como el control temprano del ritmo o la ablación con catéter, que han demostrado ser efectivas para mantener el ritmo cardíaco normal y reducir problemas graves como el derrame cerebral y la insuficiencia cardíaca. Este cambio de un tratamiento reactivo a una prevención activa es fundamental en la medicina moderna. La presente investigación, al aplicar métodos de aprendizaje automático como SVM con una extracción de características detallada (VFC y morfología de la onda P por ventanas), demuestra un enfoque sólido para abordar un problema que era un desafío considerable en 2001. El resultado de 21/28, valida la capacidad de estos métodos para extraer información predictiva relevante de las señales de ECG. La elección de características como la VFC y la morfología de la onda P es pertinente, ya que se sabe que los cambios en la actividad eléctrica auricular y la regulación autonómica preceden a los episodios de FA [Jin Yeongbong \(2025\)](#). La segmentación en ventanas temporales permite al modelo capturar la dinámica de estos cambios a lo largo del tiempo, lo cual es crucial para la predicción de eventos. Los avances en el aprendizaje profundo sugieren un margen significativo para futuras mejoras en la predicción de arritmias. Esto no disminuye el valor de la presente investigación, sino que la posiciona como un paso intermedio crucial que valida la aplicación de técnicas de ML más tradicionales y sienta las bases para explorar modelos de DL más complejos. La utilidad de este tipo de sistemas va más allá de la investigación. En el día a día, un sistema que pueda detectar señales de PAF a tiempo podría integrarse en dispositivos de monitoreo continuo (como relojes inteligentes o parches de ECG), permitiendo a los pacientes y

médicos tomar medidas proactivas. Esto podría llevar a una detección más temprana, un manejo más eficaz y, en última instancia, a una mejora en la calidad de vida y la reducción de complicaciones graves para los pacientes con riesgo de PAF.

Bibliografía

- Camm AJ, Kirchhof P, Lipop T, and Task Force for the Management of Atrial Fibrillation of the European Society of Cardiology (ESC) (2010). Guidelines for the management of atrial fibrillation: The task force for the management of atrial fibrillation of the european society of cardiology (esc). *EP Europace*, 12(10):1360–1420.
- Castro, H., Garcia-Racines, J. D., and Bernal-Noreña, A. (2021). Methodology for the prediction of paroxysmal atrial fibrillation based on heart rate variability feature analysis. *Heliyon*, 7(e08244).
- Chen, W., Zheng, P., Bu, Y., Xu, Y., and Lai, D. (2024). Achieving real-time prediction of paroxysmal atrial fibrillation onset by convolutional neural network and sliding window on r-r interval sequences. *Bioengineering*, 11(9).
- Chui, C. K. (1992). *An introduction to wavelets*, volume 1. Academic press.
- Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20(3):273–297.
- Costin, H., Rotariu, C., and Păsărică, A. (2013). Atrial fibrillation onset prediction using variability of ecg signals. In *2013 8TH INTERNATIONAL SYMPOSIUM ON ADVANCED TOPICS IN ELECTRICAL ENGINEERING (ATEE)*, pages 1–4.
- Cristianini, N. and Scholkopf, B. (2002). Support vector machines and kernel methods: The new generation of learning machines. *AI Magazine*, 23(3):31.
- De Luna, A. B., Batchvarov, V. N., and Malik, M. (2006). The morphology of the electrocardiogram. *The ESC Textbook of Cardiovascular Medicine Blackwell Publishing*, 35.
- Ebrahimzadeh, E., Kalantari, M., Joulani, M., Shahraki, R. S., Fayaz, F., and Ahmadi, F. (2018). Prediction of paroxysmal atrial fibrillation: A machine learning based approach using combined feature vector and mixture of expert classification on hrv signal. *Computer Methods and Programs in Biomedicine*, 165:53–67.
- Fatih Gündüz, A. and Fatih Talu, M. (2023). Atrial fibrillation classification and detection from ecg recordings. *Biomedical Signal Processing and Control*, 82:104531.
- Fletcher, T. (2009). Support vector machines explained. *Tutorial paper*, 1118:1–19.

- Gunawardene, M. A. and Willems, S. (2022). Atrial fibrillation progression and the importance of early treatment for improving clinical outcomes. *EP Europace*, 24(Supplement₂) : ii22 – –ii28.
- Hampton, J. and Hampton, J. (2025). *ECG fácil*. Elsevier Health Sciences.
- Jakkula, V. (2006). Tutorial on support vector machine (svm). *School of EECS, Washington State University*, 37(2.5):3.
- Jin Yeongbong, Ko Bonggyun, C. W. C. K.-H. L. K. H. (2025). Explainable paroxysmal atrial fibrillation diagnosis using an artificial intelligence-enabled electrocardiogram. *Korean J Intern Med*, 40(2):251–261.
- Joglar, J. A., Chung, M. K., Armbruster, A. L., Benjamin, E. J., Chyou, J. Y., Cronin, E. M., Deswal, A., Eckhardt, L. L., Goldberger, Z. D., Gopinathannair, R., Gorenek, B., Hess, P. L., Hlatky, M., Hogan, G., Ibeh, C., Indik, J. H., Kido, K., Kusumoto, F., Link, M. S., Linta, K. T., Marcus, G. M., McCarthy, P. M., Patel, N., Patton, K. K., Perez, M. V., Piccini, J. P., Russo, A. M., Sanders, P., Streur, M. M., Thomas, K. L., Times, S., Tisdale, J. E., Valente, A. M., and Wagoner, D. R. V. (2024). 2023 acc/aha/accp/hrs guideline for the diagnosis and management of atrial fibrillation: A report of the american college of cardiology/american heart association joint committee on clinical practice guidelines. *Circulation*, 149(1):e1–e156.
- Krstacic, G., Garnberger, D., Smuc, T., and Krstacic, A. (2001). Some important r-r interval based paroxysmal atrial fibrillation predictors. In *Computers in Cardiology 2001. Vol.28 (Cat. No.01CH37287)*, pages 409–412.
- Maier, C., Bauch, M., and Dickhaus, H. (2001). Screening and prediction of paroxysmal atrial fibrillation by analysis of heart rate variability parameters. In *Computers in Cardiology 2001. Vol.28 (Cat. No.01CH37287)*, pages 129–132.
- Makowski, D., Pham, T., Lau, Z. J., Brammer, J. C., Lespinasse, F., Pham, H., Schölzel, C., and Chen, S. H. A. (2021). NeuroKit2: A python toolbox for neurophysiological signal processing. *Behavior Research Methods*, 53(4):1689–1696.
- Mohebbi, M. and Ghassemian, H. (2008). Detection of atrial fibrillation episodes using svm. In *2008 30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 177–180.
- Mohebbi, M. and Ghassemian, H. (2012). Prediction of paroxysmal atrial fibrillation based on non-linear analysis and spectrum and bispectrum features of the heart rate variability signal. *Computer Methods and Programs in Biomedicine*, 105(1):40–49.
- Narin, A., Isler, Y., Ozer, M., and Perc, M. (2018). Early prediction of paroxysmal atrial fibrillation based on short-term heart rate variability. *Physica A: Statistical Mechanics and its Applications*, 509:56–65.
- Nguyen, Q. H., Nguyen, B. P., Nguyen, T. B., Do, T. T., Mbinta, J. F., and Simpson, C. R. (2021). Stacking segment-based cnn with svm for recognition of atrial fibrillation from single-lead ecg recordings. *Biomedical Signal Processing and Control*, 68:102672.

- Park, J.-S., Lee, S.-W., and Park, U. (2017). R peak detection method using wavelet transform and modified shannon energy envelope. *Journal of healthcare engineering*, 2017(1):4901017.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Percival, D. B. and Walden, A. T. (2000). *Wavelet methods for time series analysis*, volume 4. Cambridge university press.
- Petmezas, G., Haris, K., Stefanopoulos, L., Kilintzis, V., Tzavelis, A., Rogers, J. A., Katsaggelos, A. K., and Maglaveras, N. (2021). Automated atrial fibrillation detection using a hybrid cnn-lstm network on imbalanced ecg datasets. *Biomedical Signal Processing and Control*, 63:102194.
- PhysioNet (2001). The physionet/computing in cardiology challenge 2001: Prediction of paroxysmal atrial fibrillation. <https://physionet.org/content/challenge-2001/>. Accessed: 2025-08-27.
- Pourbabaei, B., Roshtkhari, M. J., and Khorasani, K. (2018). Deep convolutional neural networks and learning ecg features for screening paroxysmal atrial fibrillation patients. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 48(12):2095–2104.
- Schölkopf, B. and Smola, A. J. (2002). *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press.
- Schreier, G., Kastner, P., and Marko, W. (2001). An automatic ecg processing algorithm to identify patients prone to paroxysmal atrial fibrillation. In *Computers in Cardiology 2001. Vol.28 (Cat. No.01CH37287)*, pages 133–135.
- Soman, K., Loganathan, R., and Ajay, V. (2009). *Machine learning with SVM and other kernel methods*. PHI Learning Pvt. Ltd.
- Sáez, P. and Herrera, C. (2015). Proposición de un método basado en cadenas de Markov para el pronóstico de fibrilaciones auriculares paroxísticas. *Ingeniare. Revista chilena de ingeniería*, 23:449 – 457.
- Thong, T., McNames, J., Aboy, M., and Goldstein, B. (2004). Prediction of paroxysmal atrial fibrillation by analysis of atrial premature complexes. *IEEE Transactions on Biomedical Engineering*, 51(4):561–569.
- Thuraisingham, R. A. (2007). An electrocardiogram marker to detect paroxysmal atrial fibrillation. *Journal of Electrocardiology*, 40(4):344–347.
- Toledo-Pérez, D. C., Rodríguez-Reséndiz, J., Gómez-Loenzo, R. A., and Jauregui-Correa, J. C. (2019). Support vector machine-based emg signal classification techniques: A review. *Applied Sciences*, 9(20).
- Uryga, A., Olszewski, B., Pietroni, D., and Kasprówska, M. (2025). Impact of signal

length and window size on heart rate variability and pulse rate variability metrics. *Physiological Measurement*, 46(7):075006.

Zong, W. and Mark, R. G. (2001). A methodology for predicting paroxysmal atrial fibrillation based on ecg arrhythmia feature analysis. Unpublished manuscript or internal report.

Zong, W., Mukkamala, R., and Mark, R. (2001). A methodology for predicting paroxysmal atrial fibrillation based on ecg arrhythmia feature analysis. In *Computers in Cardiology 2001. Vol.28 (Cat. No.01CH37287)*, pages 125–128.